



基于深度学习算法的 视频文字去模糊系统

Video Enhancement& Deblurring System



指导老师：刘绍辉



团队成员：杨宇 胡静波 罗腾 张艺馨



目 录

CONTENTS



研究背景与研究意义

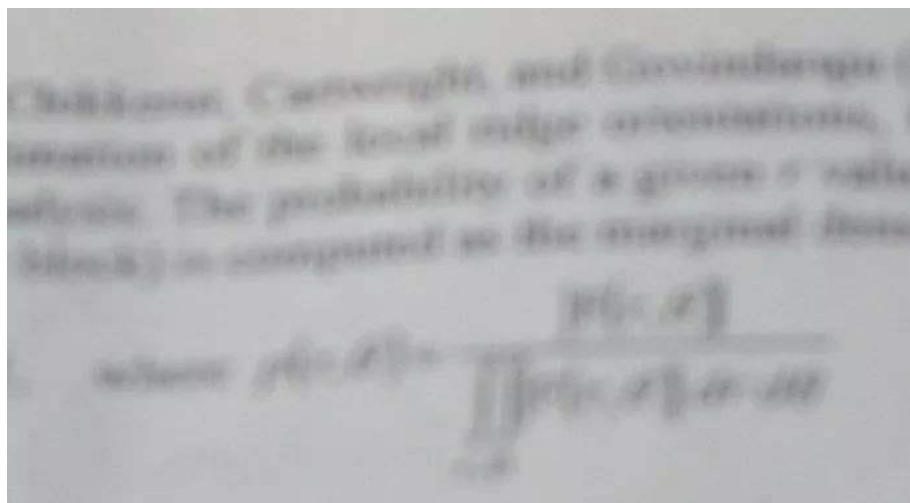


主要研究内容与实施方案




发展前景与团队合作

研究背景



图像中包含大量的信息, 其中的文本内容是重要的信息之一. 因此, 自然场景文本信息的提取是计算机视觉的一个重要研究方向。然而在许多场景下, 如希望通过摄像头监控获取某一帧图像上的文本信息时, 常由于目标速度过快等原因而导致视频中单帧所包含的文本信息模糊不清 (例如快速行驶的车辆车牌号)。

研究意义



01

能用于对日常拍摄获得的视频中的文本信息进行去模糊

02

在监控安防领域有着巨大应用潜力

03

避免了人工在大量的视频帧中搜寻文本信息，节省了人力

04

还有许多的应用场景.....

实践过程



文字检测

根据用户选中的出现模糊文字的部分，利用文字检测的模型在本帧和上下帧进行文本段检测，得到包含有文字的四边形框。




文字匹配

考量文字框的不同特征，如文字框内像素信息，文字框的大小和相对位置等，对上下帧的文字进行文字匹配的处理。



视频去模糊

将聚合的文本段送入去模糊模型中进行处理。



文字识别与输出

将得到的清晰文字在图片中识别出并转化成字符串输出。




算法实现: 模糊文本段检测-CTPN算法 (TEXT DETECTION)



网络模型主要包括三个部分：卷积层、双向LSTM、全连接层

- 1、VGG16为base net提取特征，将conv5得到的feature map输出作为下一层的输入（特征提取）
- 2、用3*3滑窗扫描上面得到的feature map，也即在conv5得到的特征上做3*3的滑动窗口：每个点结合周围3*3的区域得到一个长度为 $3 \times 3 \times C$ 的特征向量（将特征图进行序列化）
- 3、将特征reshape后，输入双向LSTM，考虑了文本模糊段潜在的序列性与文本段前后的时序关联性
- 4、将Bi-LSTM的输出接入全连接层，针对文本段的特征，引入了anchor的机制，即对每一个点用k个anchor进行预测



CTPN算法流程



这一部分里我们要达到的目标是：根据文本检测的结果，得出两帧之间的多个文本框的对应关系，也就是需要找出这一帧里的每一个文本框在下一帧里的对应框，如果不存在也需要标注。在得出对应关系之后，还需进行透视变换使得每个文本框中的内容变为正视图，以期望提高后续去模糊模型的效果。

1. 透视变换 (Homograph)

图像的仿射变换指保留平行特征的变换，如整体拉伸，放缩，旋转，平行四边形化，变换后，原来平行的线仍然平行。图像的透视变换指在三维空间转换对平面的观察视角所形成的图像，变换后不保留平行特征。平面图像的透视变换和仿射变换合并成为单应性变换。

图像的变换可以用 3×3 矩阵来描述，划分为4个部分：

$$\begin{pmatrix} x' \\ y' \\ 1 \end{pmatrix} = \begin{bmatrix} A_{2 \times 2} & T_{2 \times 1} \\ V^T & s \end{bmatrix} \begin{pmatrix} x \\ y \\ 1 \end{pmatrix} = H_{3 \times 3} \begin{pmatrix} x \\ y \\ 1 \end{pmatrix} \quad (8)$$

其中 $A_{2 \times 2}$ 可以控制仿射变换， $T_{2 \times 1}$ 可以控制图像的平移， V^T 可以控制透视变换， s 可以用来调整整体缩放。现在只需要求出这个转换矩阵 H 就可以将前一帧的文本框和后一帧的进行对齐

算法实现:文本追踪-模拟退火+单应性变换 (text track)




要求出 H ，类似的算法早已经在2016年发表的论文HomographyNet中提出，将两帧图像输入，可以直接求出转换矩阵 H 。然而我们的目标是尽量节约算力，以便在移动平台上使用，所以根据前一部分求出的文本框的坐标，我们可以设计出一个比神经网络更轻量的随机化算法。


2.模拟退火

这个算法在深度学习领域早就有许多的应用，其可以比较有效地期望避开较优解，找出最优解。具体地，我们的目标是求得转换函数 H 中的九个数据，其已经被分为四个板块，则每个板块轮流进行“降温”，每次进行降温之后将 H' 带入上一帧的文本框，求出对应的下一帧的文本框期望位置，与实际位置求一个“损失”，作为评判 H 的依据。在设计损失函数的时候，需要考虑没有对应的文本框，其带来的影响应该尽量小。目前的方案是将每一对文本框相似度进行排序，优先将最接近的一对进行配对，计算损失，然后再找下一对（不包含任何已经配对的文本框）。总的损失求得之后进行“降温”。

将所有文本框进行配对之后，就可以得知用户画出的四边形在各帧之间的对应位置，就可以对每个文本框进行透视变换，以达到将待清晰化文字“标准化”的效果。




算法实现: 视频去模糊模型: VRT(A Video Restoration Transformer)




VRT总体框架：多尺度、多帧平行地进行处理，包含其特有的注意力模块TMSA

算法实现:视频去模糊模型: VRT(A Video Restoration Transformer)



传统方法：基于滑动窗口的方法和迭代法
VRT：平行计算，采用长距离帧依赖模型



效果展示

```
9.0825e-01, ..., 1.0000e+00,
6.9168e-04, 1.0000e+00],
[-7.7883e-07, 1.0000e+00, -9.0825e-01, ..., 1.0000e+00,
8.0696e-04, 1.0000e+00],
[-7.7883e-07, 1.0000e+00, -9.0825e-01, ..., 1.0000e+00,
9.2225e-04, 1.0000e+00]])), ('stage5.residual_group1.blocks.2.
[338, 337, 336, ..., 3, 2, 1],
[339, 338, 337, ..., 4, 3, 2],
...,
[672, 671, 670, ..., 337, 336, 335],
[673, 672, 671, ..., 338, 337, 336],
[674, 673, 672, ..., 339, 338, 337]])), ('stage5.residual_group1.blocks.2.
[0.0648, 0.0164, 0.0015, ..., 0.0219, -0.0018, -0.0120],
[-0.0014, -0.0041, 0.0074, ..., -0.0435, 0.0258, 0.0089],
...,
[0.0046, -0.0114, -0.0330, ..., 0.0206, 0.0187, 0.0150],
[0.0135, -0.0358, 0.0330, ..., -0.0210, 0.0373, 0.0057],
[0.0162, -0.0471, -0.0040, ..., -0.0125, -0.0206, 0.0177]])), ('
1.5051e-08, -3.7423e-08, -5.7243e-09, -4.3356e-10, -3.2504e-08,
1.8444e-08, 2.6793e-09, -1.6524e-08, -9.8236e-10, -2.4404e-08,
-6.9923e-09, -7.4028e-09, 4.0272e-08, 4.2704e-08, -4.2816e-09,
-2.5505e-09, -2.7004e-08, -9.6683e-09, -1.0543e-08, 6.7404e-09,
-1.0948e-08, -2.0150e-09, 1.2871e-08, 6.3516e-08, -6.1969e-09,
-5.8980e-08, 6.5855e-08, 3.0686e-08, -1.9090e-08, 1.3784e-08,
```

后续将对预训练模型进行针对性训练

算法实现:视频去模糊模型: VRT(A Video Restoration Transformer)



特征提取和重建: 先经过普通的卷积层在多尺度上对不同帧图片进行浅特征提取, 以待后续经过模型主体部分, 最后再经过卷积层进行特征重建




模型主体部分是多个TMSA (+光流法对齐) 模块的堆叠。TMSA模块先利用多头注意力机制将前后两帧互相向对方对齐得到两幅图, 再将它们与原始两帧经过多头自注意力机制得到的一幅图结合。之后将该特征图经过多层感知机进行特征降维和提取。最后会利用光流法进行进一步的对齐。




TMSA中涉及到的注意力机制是一种软式的对齐方法: 首先计算出前后两帧不同窗口之间相似度矩阵, 之后将该矩阵乘上待对齐的帧图像, 可以实现帧图像内窗口的平移, 达到对齐的效果。

$$\begin{aligned} X_1, X_2 &= \text{Split}_0(\text{LN}(X)) \\ Y_1, Y_2 &= \text{MMA}(X_1, X_2), \text{MMA}(X_2, X_1) \\ Y_3 &= \text{MSA}([X_1, X_2]) \\ X &= \text{MLP}(\text{Concat}_2(\text{Concat}_0(Y_1, Y_2), Y_3)) + X \\ X &= \text{MLP}(\text{LN}(X)) + X \end{aligned}$$

TMSA处理流程



TMSA进行堆叠



软式对齐,
同时设置窗口
减少计算
代价


算法实现:文本识别-CRNN+CTC算法(TEXT RECOGNITION)



1、CNN(Convolutional Neural Network)结构采用的是VGG的网络结构，但对网络的超参数进行了微调，如为了方便的将CNN的提取特征作为RNN的输入，将MAXPOOLING的核尺度从 $2*2$ 改成了 $1*2$ ，为了加速网络加入了BATCH NORMALISATION。

2、CNN的输出特征序列随后会进入RNN(Recurrent Neural Network)网络。RNN是一类用于处理序列数据的神经网络，它能够挖掘数据中的时序信息以及语义信息，正适用于文本这种具有高度时序逻辑的信息。为了防止训练时梯度的消失，算法采用了LSTM神经单元作为RNN的单元，这是因为对于序列的预测，序列的前向信息和后向信息都有助于序列的预测，所以采用了双向RNN网络。

3、最后再利用CTC算法得到最终的输出字符串，它的作用是实现字符去重（如ccaaat会被识别为cat），并引入空位符，提升文本段预测的准确性。




CRNN+CTC处理过程

算法实现:模糊文本段检测-CTPN算法 (TEXT DETECTION)



网络模型主要包括三个部分：卷积层、双向LSTM、全连接层

- 1、VGG16为base net提取特征，将conv5得到的feature map输出作为下一层的输入（特征提取）
- 2、用3*3滑窗扫描上面得到的feature map，也即在conv5得到的特征上做3*3的滑动窗口：每个点结合周围3*3的区域得到一个长度为 $3 \times 3 \times C$ 的特征向量（将特征图进行序列化）
- 3、将特征reshape后，输入双向LSTM，考虑了文本模糊段潜在的序列性与文本段前后的时序关联性
- 4、将Bi-LSTM的输出接入全连接层，针对文本段的特征，引入了anchor的机制，即对每一个点用k个anchor进行预测




CTPN算法流程

发展前景



在未来的工作中，将对以下问题展开进一步的研究:



- 1) 在个别图像中，解决算法的区域定位不准确时导致目标部分区域无法准确分割的问题.
- 2) App端Pytorch环境兼容性评估与相关底层代码迭代.
- 3) 改进网络结构,推进模型轻量化,提升识别速度与准确率,争取达到业界先进标准.
- 4) 在除Android端以外的终端部署算法,实现泛用、易用且高效的系统构建.